



Deep Learning for TextImaging

SoSe 2026
Fingerübung

Alexander Mehler

Giuseppe Abrami

Einleitung

Diese Übung dient als Einstieg in das Praktikum **Deep Learning for TextImaging** und ermöglicht Ihnen einen Einstieg im Umgang mit Java als Programmiersprache, der Verwendung von DOCKER UNIFIED UIMA INTERFACE (DUUI– Leonhardt u. a. 2023) und UIMA (Ferrucci u. a. 2009) als Annotationsformat. In dieser Übung besteht Ihre Aufgabe darin, Plenarprotokolle des deutschen Bundestages mittels DUUI einzulesen sowie mit Java insofern zu verarbeiten, dass die Ergebnisse visualisiert werden können.

Vorbemerkungen

UIMA¹ ist eine Spezifikation, sowie eine Framework-Implementierung in Java, für die Analyse von unstrukturierten Inhalten wie Text (oder auch Video oder Audio). Hierdurch wird ein Ein- und Ausgabeformat definiert, welches eine Interoperabilität verschiedener Werkzeuge ermöglicht. In UIMA werden Dokumente mittels einer *Analysis Engine* (AE) verarbeitet, die *Analysis Results* (AR) generieren. Diese beschreiben ein Dokument, oder Teile eines Dokuments, und werden als *Annotations* bezeichnet. Aufgrund des standardisierten Interfaces, von sowohl der AE als auch der AR, ermöglicht dies einen Austausch sowie die Kompatibilität verschiedener Tools. AR werden in einer Objekt-basierten Datenstruktur CAS (Common Analysis Structure) dargestellt. Diese ermöglicht eine Abbildung von Objekten mit Eigenschaften und Werten, und bietet eine einfache Vererbungshierarchie für Objekt-Typen. Sämtliche in einem CAS auftretenden Typen werden durch ein Typsystem beschrieben. Ein Typ besitzt *Features* (Attribute) und ist mittels des *JCas*-Interface direkt in Java als Klasse verwendbar.

Vorbereitungen

Installieren Sie sich die Linuxdistribution **Ubuntu 24.04** und nutzen Sie diese für die Entwicklung. Laden Sie sich die Entwicklungsumgebung IntelliJ² in der Community-Variante herunter. Installieren Sie **IntelliJ** und, sollten Sie noch kein Java-SDK auf Ihrem System haben, installieren Sie dieses ebenfalls³. **Wir verwenden für alle Aufgaben Java 21!**

¹Unstructured Information Management Architecture

²<https://www.jetbrains.com/de-de/idea/download/>

³<https://openjdk.java.net/>

Aufgabenbeschreibung

Betrachten Sie sich die Plenartexte (Reden) welche Ihnen über OLAT zur Verfügung gestellt wurden. Jedes Dokument repräsentiert eine Protokoll.

Aufgabe

Erstellen Sie ein leeres Maven-Projekt in Java und binden Sie die im OLAT hinterlegte `pom.xml`-Datei ein.

Ersetzen Sie anschließend die Zeichenkette **NAME** durch Ihre persönliche HRZ-Kennung.

1. Entwickeln Sie einen `DOCKER UNIFIED UIMA READER (DUUR)`, der die Plenarprotokolle einliest und daraus auf Reden-Ebene CAS-Repräsentationen erzeugt (Hammerla, Mehler und Abrami 2025).

Hinweis: Ein einzelnes Protokoll enthält mehrere Reden und erzeugt somit mehrere CAS-Objekte.

Optional

Erweitern Sie den bisherigen Ansatz um die Analyse unstrukturierter Texte zu ermöglichen.

2. Entwickeln Sie ein eigenes **UIMA TypeSystem**, das folgende Informationen sinnvoll abbildet:
 - Redner
 - Redehalt
 - Sitzungsinformationen
3. Erstellen Sie für jede Rede eine entsprechende CAS-Repräsentation unter Nutzung des erstellten UIMA TypeSystems.
4. Analysieren Sie die Reden mithilfe der DUUI-Komponenten:
 - `spacy`⁴
 - `ParlBertTopic`⁵
5. Implementieren Sie einen Export als DUUI-Komponente (Writer), der pro Rede die häufigsten Named Entities sowie die drei dominierenden Topics ausgibt.
6. Serialisieren Sie zusätzlich das Analyseergebnis im XML-Format, mittels `XMIWriter`.

Abgabe der Aufgabe

Ihr vollständiges fertiges Projekt laden Sie bitte bis spätestens zum **08.05.2026** als ZIP-Archiv in OLAT hoch. Für die Bearbeitung dieser Aufgabe steht Ihnen **zwei** Wochen (14 Tage) zur Verfügung.

Demonstrieren Sie Ihr Ergebnis gerne im Plenum.

⁴docker.texttechnologylab.org/textimager-duui-spacy-single-de__core__news_sm:0.1.4

⁵docker.texttechnologylab.org/parlbert-topic-german:latest

Literatur

- Ferrucci, David u. a. (2009). *Unstructured Information Management Architecture (UIMA) Version 1.0*. OASIS Standard. URL: <https://docs.oasis-open.org/uima/v1.0/uima-v1.0.html>.
- Hammerla, Leon, Alexander Mehler und Giuseppe Abrami (2025). „Standardizing Heterogeneous Corpora with DUUR: A Dual Data- and Process-Oriented Approach to Enhancing NLP Pipeline Integration“. In: *Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics*. Hrsg. von Kentaro Inui u. a. Mumbai, India: The Asian Federation of Natural Language Processing und The Association for Computational Linguistics, S. 1410–1425. ISBN: 979-8-89176-303-6. URL: <https://aclanthology.org/2025.findings-ijcnlp.87/>.
- Leonhardt, Alexander u. a. (2023). „Unlocking the Heterogeneous Landscape of Big Data NLP with DUUI“. In: *Findings of the Association for Computational Linguistics: EMNLP 2023*. Hrsg. von Houda Bouamor, Juan Pino und Kalika Bali. Singapore: Association for Computational Linguistics, S. 385–399. URL: <https://aclanthology.org/2023.findings-emnlp.29>.